

Proyecto de Bases de Datos: Reviews de Amazon

1. Descripción

El proyecto consiste en el diseño e implementación de un sistema de almacenamiento y análisis de reviews de Amazon utilizando tres tecnologías de bases de datos: MySQL (modelo relacional), MongoDB (almacenamiento documental) y Neo4J (representación en grafos). Se trabaja con cinco datasets (Toys and Games, Video Games, Digital Music, Musical Instruments y Office Products) que suman más de 500.000 reviews.

El sistema permite cargar los datos desde ficheros JSON línea a línea, visualizar estadísticas mediante gráficas (Python y Power BI), explorar relaciones entre usuarios mediante grafos en Neo4J, insertar nuevos datasets de forma incremental y generar recomendaciones de artículos basadas en filtrado colaborativo con correlación de Pearson.

2. Desarrollo

El proyecto consta de los siguientes elementos:

- Aproximadamente 5.500 líneas de código Python.
- 9 módulos (ficheros .py).
- 131 funciones.
- 1 clase (en el segundo opcional).
- 5 ficheros de datos JSON (4 iniciales + 1 adicional)
- 6 csv creados al ejecutar.
- Librerías:
 - pymysql, pymongo, neo4j (conexión a BBDD)
 - matplotlib, wordcloud (visualización)
 - tkinter (interfaz gráfica del dashboard)




Figura 1. Esquema relacional del modelo de datos

1. Resultados

El sistema carga correctamente más de 500.000 reviews en MySQL y MongoDB con deduplicación automática y trazabilidad categórica. Las siete visualizaciones funcionan tanto en el menú por terminal como en el dashboard gráfico con Tkinter. El modelo de ML obtiene un MAE de 0.84 (error menor a 1 punto en escala 1–5).



Figura 2. Reviews por año de todos los productos




Figura 3. Histograma por nota




Figura 4. Similitudes entre los 30 usuarios con más reviews




Figura 5. Usuarios que han consumido más de un tipo de artículo